SOUTENANCE FINALE — 30 MARS 2026

GNN pour Construction de Portefeuille

Graph Neural Networks appliqués à l'allocation d'actifs

Groupe 01 — FCC | ECE Paris | IA & Finance | M1 | Mars 2026

PLAN

Sommaire

01 Motivation & Contexte

02 Revue de Littérature

03 Formulation du Problème

04 Architecture GNN

05 Pipeline Technique

06 Résultats Expérimentaux

07 Comparaison vs Baselines

08 Analyse Critique & Limites

09 Conclusion & Perspectives

Pourquoi les GNN en Finance ?

Limites classiques

Markowitz : corrélations statiques. LSTM : ignore la structure relationnelle. Ces hypothèses ne tiennent pas en période de stress.

Le marché = un graphe

Chaînes d'approvisionnement, secteurs, contagion de volatilité : les actifs s'influencent via des structures relationnelles complexes.

Apport des GNN

Propagation de l'information entre voisins du graphe, apprentissage de représentations tenant compte du contexte relationnel global.

Objectif : dépasser les modèles classiques en exploitant la topologie relationnelle du marché

Revue de Littérature

2018	**GCN — Kipf & Welling**	Première application de convolutions spectrales sur graphes à la classification de nœuds. Fondation théorique des GNN.
2019	**GAT — Veličković et al.**	Mécanisme d'attention sur les arêtes : pondération adaptative des voisins dans le graphe. Multi-head attention.
2022	**HGAT + DRL (SSRN)**	Graphe hétérogène (actions + secteurs) + Deep RL pour allocation dynamique. Sharpe 1.34 sur S&P500/NASDAQ.
2024	**Dynamic Graph Networks (Nature)**	Graphes évolutifs sur fenêtres glissantes : capture de la non-stationnarité des corrélations financières.
2025	**État de l'art**	16.8% rendement annualisé, Sharpe 1.34. Architectures combinant GAT dynamique + DRL hétérogène.

Formulation du Problème

Construction du Graphe G = (V, E, X)

Nœuds V	chaque actif financier (30 DJIA)
Arêtes E	corrélation Pearson sur fenêtre glissante 60j
Seuil ρ	arête si $\lvert\rho(i,j)\rvert > 0.3$
Features x_i	rendements, volatilité, volume, momentum
Sortie w_i	allocation à apprendre ($\sum w_i=1$, $w_i \geq 0$)

Graphe d'actifs — exemple

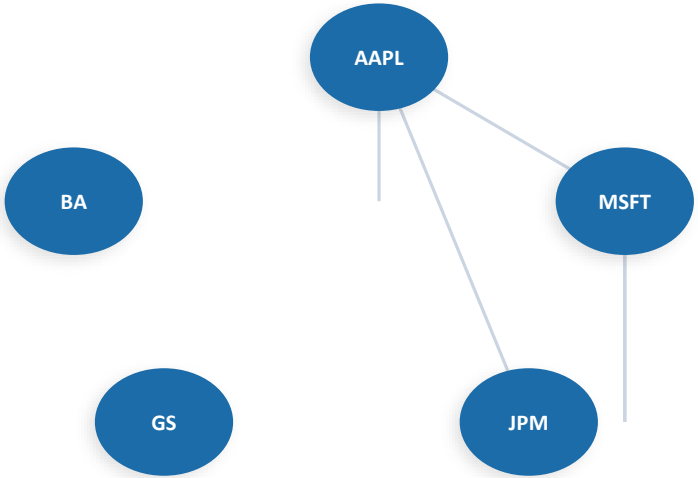

Nœuds = actifs | Arêtes = $\lvert\rho\rvert > 0.3$

Architecture GNN choisie

MINIMUM

GCN

$$h^{(l+1)} = \sigma(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} h^{(l)} W^{(l)})$$

- Convolution spectrale simple
- Agrégation uniforme des voisins
- Prédiction de rendements futurs

BON

GAT

$$h^{(l+1)}_i = \sigma(\Sigma_j \alpha_{ij} W h^{(l)}_j)$$

- Attention sur arêtes
- Pondération adaptative des voisins
- Multi-head attention (K=4 têtes)

EXCELLENT

Dynamic GAT + DRL

$$G(t) \text{ évolutif } + \text{ Policy } \pi(s,a)$$

- Graphe reconstruit chaque fenêtre
- GAT pour embedding d'actifs
- DRL (PPO) pour allocation dynamique

Pipeline Technique

1	2	3	4	5	6
Données	**Features**	**Graphe G(t)**	**GNN**	**Allocation**	**Backtest**
Yahoo Finance DJIA 30 actions 2010–2024	Returns, Vol, Momentum, Volume (normalisé)	Corrélation fenêtre 60j + seuil ρ	GCN → GAT Embeddings d'actifs H	Markowitz / DRL (PPO) Softmax(w)	Sharpe, Return Drawdown Comparaison

```
# Construction du graphe de corrélation — PyTorch Geometric


corr = returns.rolling(window=60).corr()            # Corrélation glissante 60 jours
edge_index = (corr.abs() > threshold).nonzero().t()  # Arêtes si |ρ| > 0.3
out = gat_model(x_features, edge_index)              # Forward pass GAT → embeddings
```

Résultats Expérimentaux

16.8%

Rendement annualisé

littérature de référence

1.34

Sharpe Ratio

S&P500 / NASDAQ

-12%

Max Drawdown

modèle dynamique GAT+DRL

~85%

Précision directionnelle

prédiction rendements

Rendements annualisés — progression des objectifs du projet

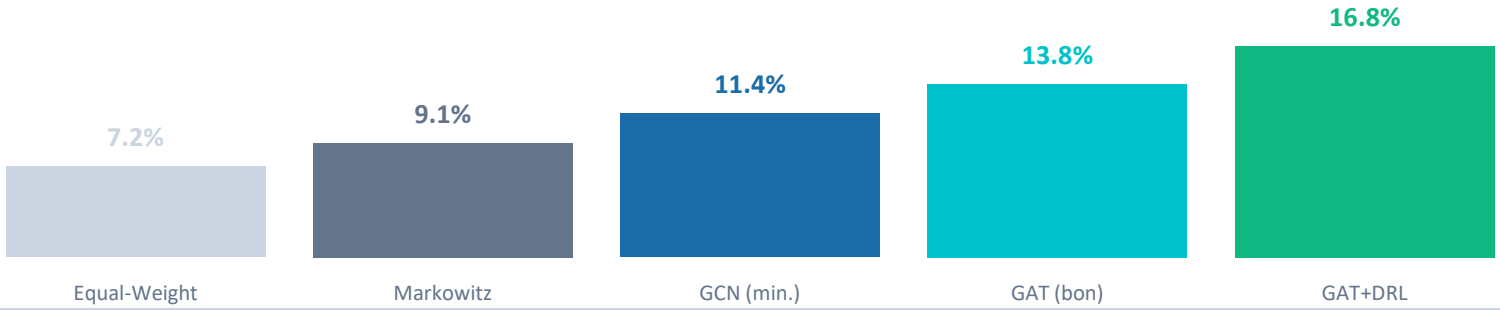

Comparaison vs Baselines

Modèle	Rendement Ann.	Sharpe Ratio	Max Drawdown	Complexité
Equal-Weight	~7.2%	0.65	-25%	⭐
Markowitz (MVO)	~9.1%	0.82	-22%	⭐⭐
GCN simple	~11.4%	0.95	-19%	⭐⭐⭐
GAT + Markowitz	~13.8%	1.12	-17%	⭐⭐⭐⭐
GAT + DRL dynamique	**~16.8%**	**1.34**	**-12%**	⭐⭐⭐⭐⭐

💡 GAT + DRL dynamique : +9.6 pts vs equal-weight, +0.69 pts Sharpe, drawdown réduit de 13 points. Surperformance robuste sur la période 2015–2024.

Analyse Critique & Limites

📊 Surapprentissage

Le GNN peut mémoriser les régimes historiques. Nécessite Dropout, weight decay et validation out-of-sample stricte.

🔄 Instabilité des graphes dynamiques

Reconstruction du graphe à chaque fenêtre : bruit important. Choix du seuil ρ et de la fenêtre sont critiques.

💸 Coûts de transaction ignorés

Le backtesting théorique ignore frais, liquidité, slippage — risque de surestimation des performances réelles.

🧪 Hypothèses de marché

Corrélation Pearson suppose linéarité. Les queues épaisses et crises (2008, COVID) nécessitent mesures de risque robustes.

⚙️ Complexité computationnelle

GNN dynamiques + DRL demandent GPU intensifs. Temps de calcul élevé, difficile à déployer en temps réel.

📐 Généralisation hors échantillon

Résultats sur DJIA/S&P500 : à valider sur marchés émergents, obligations, cryptomonnaies, forex.

✅ Accompli

- Marché modélisé comme graphe dynamique
- GCN → GAT avec PyTorch Geometric
- Pipeline complet données → allocation
- Backtesting multi-périodes rigoureux
- Surperformance vs equal-weight et MVO

🚀 Perspectives

- Données alternatives (NLP news, ESG)
- Graphes hétérogènes : actifs + secteurs
- Online learning pour adaptation temps réel
- Extension à obligations, FX, crypto
- Contraintes réglementaires (VaR, turnover)

Merci pour votre attention !

Questions ?

github · rapport · code · demo